

Chapitre 2

Nettoyage et prétraitement des données

Pr. A. Fadil

EMSI Rabat

20 octobre 2025

- 1 Introduction
- 2 Méthodes de traitement des données manquantes
 - Types de données manquantes
 - Méthodes de traitement
 - Suppression des données manquantes
 - Imputation simple (remplacement par une valeur)
 - Imputation avancée
- 3 Techniques de nettoyage des données
 - Valeurs aberrantes
 - Normalisation et standardisation
 - Traitement des doublons

Introduction

1 Introduction

2 Méthodes de traitement des données manquantes

- Types de données manquantes
- Méthodes de traitement
 - Suppression des données manquantes
 - Imputation simple (remplacement par une valeur)
 - Imputation avancée

3 Techniques de nettoyage des données

- Valeurs aberrantes
- Normalisation et standardisation
- Traitement des doublons

Introduction

Les données manquantes (ou *missing data*) sont des valeurs absentes dans un jeu de données. Elles peuvent résulter :

- d'erreurs de saisie ou de mesure,
- de non-réponses dans des enquêtes,
- de problèmes techniques (capteurs, bases de données, etc.).

Leur traitement est une étape essentielle du prétraitement des données, car les valeurs manquantes peuvent biaiser les analyses statistiques ou fausser les modèles d'apprentissage automatique.

Introduction

Les données manquantes (ou *missing data*) sont des valeurs absentes dans un jeu de données. Elles peuvent résulter :

- d'erreurs de saisie ou de mesure,
- de non-réponses dans des enquêtes,
- de problèmes techniques (capteurs, bases de données, etc.).

Leur traitement est une étape essentielle du prétraitement des données, car les valeurs manquantes peuvent biaiser les analyses statistiques ou fausser les modèles d'apprentissage automatique.

Introduction

Les données manquantes (ou *missing data*) sont des valeurs absentes dans un jeu de données. Elles peuvent résulter :

- d'erreurs de saisie ou de mesure,
- de non-réponses dans des enquêtes,
- de problèmes techniques (capteurs, bases de données, etc.).

Leur traitement est une étape essentielle du prétraitement des données, car les valeurs manquantes peuvent biaiser les analyses statistiques ou fausser les modèles d'apprentissage automatique.

Introduction

Les données manquantes (ou *missing data*) sont des valeurs absentes dans un jeu de données. Elles peuvent résulter :

- d'erreurs de saisie ou de mesure,
- de non-réponses dans des enquêtes,
- de problèmes techniques (capteurs, bases de données, etc.).

Leur traitement est une étape essentielle du prétraitement des données, car les valeurs manquantes peuvent biaiser les analyses statistiques ou fausser les modèles d'apprentissage automatique.

Introduction

Les données manquantes (ou *missing data*) sont des valeurs absentes dans un jeu de données. Elles peuvent résulter :

- d'erreurs de saisie ou de mesure,
- de non-réponses dans des enquêtes,
- de problèmes techniques (capteurs, bases de données, etc.).

Leur traitement est une étape essentielle du prétraitement des données, car les valeurs manquantes peuvent biaiser les analyses statistiques ou fausser les modèles d'apprentissage automatique.

Méthodes de traitement des données manquantes

1 Introduction

2 Méthodes de traitement des données manquantes

- Types de données manquantes
- Méthodes de traitement
 - Suppression des données manquantes
 - Imputation simple (remplacement par une valeur)
 - Imputation avancée

3 Techniques de nettoyage des données

- Valeurs aberrantes
- Normalisation et standardisation
- Traitement des doublons

Types de données manquantes

1 Introduction

2 Méthodes de traitement des données manquantes

- Types de données manquantes
- Méthodes de traitement
 - Suppression des données manquantes
 - Imputation simple (remplacement par une valeur)
 - Imputation avancée

3 Techniques de nettoyage des données

- Valeurs aberrantes
- Normalisation et standardisation
- Traitement des doublons

Types de données manquantes

On distingue généralement trois types de données manquantes :

- 1 **MCAR** (Manquant complètement aléatoire) : l'absence est indépendante des données observées et non observées.
- 2 **MAR** (Manquant aléatoirement) : l'absence dépend des données observées mais pas des non observées.
- 3 **MNAR** (Manquant non aléatoire) : l'absence dépend des valeurs manquantes elles-mêmes.

Exemples I

Âge	Taille (cm)	Poids (kg)
21	165	72.5
22	170	86
35	175	81
40	–	93
54	180	63
57	165	88
67	–	78
72	172	82

Exemples II

Revenu	Visites
100 000	2
60 000	1
400 000	10
25 000	—
160 000	3
12 000	—
320 000	7
80 000	1
32 000	—

Exemples III

REVENU	ÂGE	SEXE
100 000	32	Masculin
60 000	43	Féminin
—	54	Féminin
80 000	61	Masculin
—	38	Féminin
12 000	26	Féminin
25 000	51	Masculin
—	46	Masculin

Méthodes de traitement

1 Introduction

2 Méthodes de traitement des données manquantes

- Types de données manquantes
- Méthodes de traitement
 - Suppression des données manquantes
 - Imputation simple (remplacement par une valeur)
 - Imputation avancée

3 Techniques de nettoyage des données

- Valeurs aberrantes
- Normalisation et standardisation
- Traitement des doublons

Introduction aux méthodes

Il existe plusieurs méthodes pour traiter les données manquantes. Dans ce cours, nous présenterons quelques-unes des plus courantes ; les autres seront abordées dans un mini-projet.

Les données manquantes avec Pandas

```
1 import pandas as pd
2 import numpy as np
3
4 data = {
5     'user_id': [1, 2, 3, 4, 5, 6, 7, 8,8],
6     'age': [25, 32, np.nan, 45, 28, np.nan, 35, 40,40],
7     'income': [50000, np.nan, 75000, 80000, np.nan, 110000,
8               120000, np.nan,np.nan],
9     'click_rate': [0.15, 0.22, 0.18, np.nan, 0.25, 0.30, np.nan,
10                  0.12,0.12]
11 }
12
13 df = pd.DataFrame(data)
14 print("Valeurs manquantes :")
15 print(df.isnull())
16 print(df.isnull().sum())
```

Suppression des lignes (listwise deletion)

- Simple à mettre en œuvre.
- Risque de perte d'informations importantes.

```
1 df_clean = df.dropna()
```

Suppression des colonnes (variable deletion)

- On supprime les variables trop incomplètes (ex. > 40 % de valeurs manquantes).
- À éviter si la variable est importante pour l'analyse.

```
1 df_clean = df.dropna(axis=1)
```

Remplacement par la moyenne, médiane ou mode

- Moyenne pour les variables continues, mode pour les catégorielles.
- Facile à appliquer, conserve la taille du jeu de données.
- Peut réduire la variance et biaiser les corrélations.

```
1 df['age'].fillna(df['age'].mean(), inplace=True)
```

Remplacement par une valeur fixe

- Simple à interpréter.
- Peut introduire des valeurs artificielles.

```
1 df['age'].fillna(15, inplace=True)
```

Imputation par régression

- On prédit la valeur manquante à partir d'autres variables.
- Utilise les relations entre variables.
- Suppose un modèle linéaire et sensible aux valeurs extrêmes.

Imputation par les k plus proches voisins (k-NN)

- Remplace une valeur manquante par la moyenne (ou le mode) des k voisins les plus proches.
- Plus précis, mais coûteux en calcul.

Techniques de nettoyage des données

1 Introduction

2 Méthodes de traitement des données manquantes

- Types de données manquantes
- Méthodes de traitement
 - Suppression des données manquantes
 - Imputation simple (remplacement par une valeur)
 - Imputation avancée

3 Techniques de nettoyage des données

- Valeurs aberrantes
- Normalisation et standardisation
- Traitement des doublons

Valeurs aberrantes

1 Introduction

2 Méthodes de traitement des données manquantes

- Types de données manquantes
- Méthodes de traitement
 - Suppression des données manquantes
 - Imputation simple (remplacement par une valeur)
 - Imputation avancée

3 Techniques de nettoyage des données

- Valeurs aberrantes
- Normalisation et standardisation
- Traitement des doublons

Définition

Les valeurs aberrantes sont des valeurs très éloignées de la norme et non représentatives des données. Elles peuvent résulter d'une faute de saisie ou de circonstances exceptionnelles. Elles risquent de fausser les analyses ou les modèles.

Méthode IQR

La méthode IQR (*Interquartile Range*) identifie les valeurs aberrantes à partir des quartiles :

$$IQR = Q3 - Q1$$

Une observation est considérée aberrante si elle est en dehors de :

$$[Q1 - 1.5 \times IQR, Q3 + 1.5 \times IQR]$$

Normalisation et standardisation

1 Introduction

2 Méthodes de traitement des données manquantes

- Types de données manquantes
- Méthodes de traitement
 - Suppression des données manquantes
 - Imputation simple (remplacement par une valeur)
 - Imputation avancée

3 Techniques de nettoyage des données

- Valeurs aberrantes
- Normalisation et standardisation
- Traitement des doublons

Concept

Cette technique ramène les variables à une même échelle, importante pour de nombreux algorithmes d'apprentissage.

Normalisation Min-Max

$$X_{norm} = \frac{X - X_{min}}{X_{max} - X_{min}}$$

```
1  sl = df.copy()
2  for c in sl.columns:
3      sl[c] = (sl[c] - sl[c].min()) / (sl[c].max() - sl[c].min())
4  print(sl)
5  sl.plot(kind='bar')
6  plt.show()
```

Méthode du Z-score

$$X_z = \frac{X - \mu}{\sigma},$$

où μ est la moyenne et σ est l'écart-type.

```
1  sl = df.copy()
2  for c in sl.columns:
3      sl[c] = (sl[c] - sl[c].mean()) / sl[c].std()
4  print(sl)
5  sl.plot(kind='bar')
6  plt.show()
```

Traitement des doublons

1 Introduction

2 Méthodes de traitement des données manquantes

- Types de données manquantes
- Méthodes de traitement
 - Suppression des données manquantes
 - Imputation simple (remplacement par une valeur)
 - Imputation avancée

3 Techniques de nettoyage des données

- Valeurs aberrantes
- Normalisation et standardisation
- **Traitement des doublons**

Détection des doublons

```
1 duplicate_rows = df[df.duplicated()]
```

Suppression des doublons

```
1 cleaned_df = df.drop_duplicates()
```

Travail pratique (TP)

À l'aide des méthodes vues dans ce chapitre, traitez les données manquantes et nettoyez le fichier `data_1.xlsx`.